

Fundamentos Matemáticos e Computacionais de Machine Learning

Especialização em Machine Learning e Big Data




Profa. Dra. Juliana Felix

jufelix16@uel.br





Critérios de Parada

Treinamento do Modelo





Número de épocas





Custo não se altera depois de x épocas



Usando um valor muito alto para alpha



Usando um valor baixo para o alpha



Usando um "bom" alpha





Regressão Linear Múltipla

Múltiplas entradas (features)

Área (m ²)	Quartos	Andares	Idade	Valor (R\$1000)
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
...

Entrada/Saída dos dados

Neste caso, cada **amostra** possui dados de diversas variáveis:

- Entrada:
 - Área, x_1
 - Quartos, x_2
 - Andares, x_3
 - Idade, x_4
- Saída:
 - Valor, y

Entrada/Saída dos dados

Neste caso, cada **amostra** possui dados de diversas variáveis:

- Entrada:
 - Área, x_1
 - Quartos, x_2
 - Andares, x_3
 - Idade, x_4
- Saída:
 - Valor, y

$$y = \theta_0 + \theta_1 \cdot x_1 + \theta_2 \cdot x_2 + \theta_3 \cdot x_3 + \theta_4 \cdot x_4$$


Modelo geral

$$h_{\theta}(x) = \theta_0 + \theta_1 \cdot x_1 + \theta_2 \cdot x_2 + \cdots + \theta_n \cdot x_n$$

Função custo

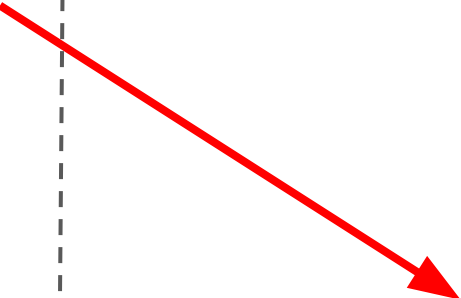
O objetivo continua o mesmo:

$$J(\theta_0, \theta_1, \theta_2, \theta_3, \theta_4) = \left[\frac{1}{2m} \sum_{i=1}^m \left(y^{(i)} - h \left(x^{(i)} \right) \right)^2 \right]$$


$$\min_{\Theta} J(\Theta) = \left[\frac{1}{2m} \sum_{i=1}^m \left(y^{(i)} - h \left(x^{(i)} \right) \right)^2 \right]$$

Gradiente descendente

```
repeat{  
  for (j=0;j<n;j++)  
     $new\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\Theta)$   
  
  for (j=0;j<n;j++)  
     $\theta_j = new\theta_j$   
}until(stop_condition)
```



$$J(\Theta) = \left[\frac{1}{2m} \sum_{i=1}^m \left(y^{(i)} - h \left(x^{(i)} \right) \right)^2 \right]$$




Regressão **Linear?**

Regressão Linear


Housing price prediction.




Housing price prediction.




Regressão Linear




$$y = f(x) = x$$




$$y = f(x) = x^2$$




$$y = f(x) = x^3$$



$$y = f(x) = \sqrt{x}$$



$$y = f(x) = |x|$$



$$y = f(x) = 2^x$$

Outras funções que podem representar os problemas...

$$h_{\theta} = \theta_0 + \theta_1 \cdot x + \theta_2 x^2$$


$$h_{\theta} = \theta_0 + \theta_1 \cdot x + \theta_2 x^2 + \theta_3 x^3$$

$$h_{\theta} = \theta_0 + \theta_1 \cdot x + \theta_2 \sqrt{x}$$

Regressão Linear

Neste exemplo, a função $h_{\theta} = \theta_0 + \theta_1 \cdot x + \theta_2 \sqrt{x}$ parece representar os dados de forma melhor que uma reta.


Housing price prediction.



Regressão Linear

$$h_{\theta} = \theta_0 + \theta_1 \cdot x + \theta_2 \sqrt{x}$$

Housing price prediction.



$$\begin{aligned} x_1 &= x \\ x_2 &= \sqrt{x} \end{aligned}$$

$$h_{\theta} = \theta_0 + \theta_1 \cdot x_1 + \theta_2 \cdot x_2$$

Regressão Linear

$$h_{\theta} = \theta_0 + \theta_1 \cdot x + \theta_2 \cdot x^2 + \theta_3 \cdot x^3$$

Temos uma **transformação**, e as features continuam sendo lineares

$$\begin{aligned}x_1 &= x \\x_2 &= x^2 \\x_3 &= x^3\end{aligned}$$

$$h_{\theta} = \theta_0 + \theta_1 \cdot x_1 + \theta_2 \cdot x_2 + \theta_3 \cdot x_3$$



Problemas de Classificação

Aprendizado supervisionado

Técnica na qual o algoritmo de aprendizado recebe um conjunto de dados rotulados que define aquilo que deverá ser buscado pelo algoritmo




Classificação

Classificação é uma subcategoria do **aprendizado supervisionado**, cujo objetivo é **predizer se** uma instância (conjunto de features) **pertence a uma determinada classe**.

Classificação

- Diferente da regressão, não estamos interessados em construir um modelo que seja capaz de aproximar os valores de uma função.
- O interesse da classificação é o de decidir se algo pertence ou não a um grupo (classe)




Classificação

Existem dois tipos de problemas de classificação:

- Classificação **Binária**
- Classificação **Multiclasse**

Classificação Binária

- Decidir se um email é um "spam" ou não
- Diagnosticar se um paciente tem uma determinada doença ou não
- Identificar se um animal é um gato ou cachorro
- Classe "positiva" vs. "negativa"
 - A saída esperada y é um valor dentro um conjunto de 2 elementos previamente definidos, por exemplo, $y \in \{0, 1\}$




Classificação Multiclasse

- Reconhecimento de dígitos (0–9), 10 classes
- Diagnosticar se um paciente tem uma entre uma lista de doenças
- Identificar se um animal é um gato, cachorro, peixe, ou ave
- Categorizar resenhas de filme como "positivas", "negativas", ou "neutras"
- A saída esperada y é um valor dentro um conjunto de n elementos previamente definidos, por exemplo, $y \in \{1, 2, 3, \dots, n\}$

0	0	0	0	0
1	1	1	1	1
2	2	2	2	2
3	3	3	3	3
4	4	4	4	4
5	5	5	5	5
6	6	6	6	6
7	7	7	7	7
8	8	8	8	8
9	9	9	9	9



Machine Learning Model




Classificação Multiclasse


Na prática, ao invés de construir um classificador multiclasse, uma tática bastante utilizada consiste na construção de vários classificadores binários para realizar a mesma tarefa.

- A técnica é conhecida como one-vs-all (um-contra-todos)
- Idealmente, o resultado final consiste na escolha do classificador que retornou "sim" para a classe desejada, enquanto os demais classificadores retornaram "não".


Classificação




Classificação




Classificação




Classificação



Classificação



Classificação






Regressão Logística

Regressão Logística

Função logística



$$f(x) = \frac{L}{1 + e^{-k(x-x_0)}}$$

- e = base dos logaritmos naturais (número de Euler)
- x_0 = valor do ponto médio da curva sigmóide
- L = valor máximo da curva
- k = declividade da curva




Função Hipótese $h(x)$

$$z = \theta_0 + \theta_1 x$$




$$h(x) = g(z) = \frac{1}{1 + e^{-z}}$$



Interpretação de $h(x)$

Temos $h(x) = g(z) = \frac{1}{1 + e^{-z}}$ sendo que $z = \theta_0 + \theta_1 x$

- $y = 1$, se $g(z) \geq 0.5$
- $y = 0$, se $g(z) < 0.5$
- $g(z) = 0.5$, se $z = 0$



Interpretação de $h(x)$

Em um problema multi característico, supondo $z = \theta_0 + \theta_1 x_1 + \theta_2 x_2$

E assumindo que $\theta_0 = -2$, $\theta_1 = -1$, $\theta_2 = 1$

Teremos $z = -2 - x_1 + x_2$

Quando $z = 0$, teremos


$$-2 - x_1 + x_2 = 0$$

$$-x_1 + x_2 = 2$$

Quando $x_1 = 0$, temos que


$$x_2 = 2 + x_1$$

$$x_2 = 2$$




Interpretação de $h(x)$

Temos $h(x) = g(z) = \frac{1}{1 + e^{-z}}$ sendo que $z = -2 - x_1 + x_2$



Ponto crítico!




Dados não-lineares

$$z = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2$$

$$h(x) = g(z) = \frac{1}{1 + e^{-z}}$$

Assim como na regressão linear, a regressão logística permite que o modelo ajuste tanto dados lineares quanto não-lineares





Função Custo

$$h(x) = g(z) = \frac{1}{1 + e^{-z}}$$

$$z = \theta_0 + \theta_1 x$$

$$Cost(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$



Função Custo

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

$$\text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) = -y \cdot \log(h_{\theta}(x)) - (1 - y) \cdot \log(1 - h_{\theta}(x))$$

$$\min_{\Theta} J(\Theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \cdot \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \cdot \log(1 - h_{\theta}(x^{(i)}))$$

Gradiente Descendente

$$\min_{\Theta} J(\Theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \cdot \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \cdot \log(1 - h_{\theta}(x^{(i)}))$$

```
repeat{
  for (j=0; j<n; j++)
    newθj = θj - α  $\frac{\partial}{\partial \theta_j} J(\Theta)$ 

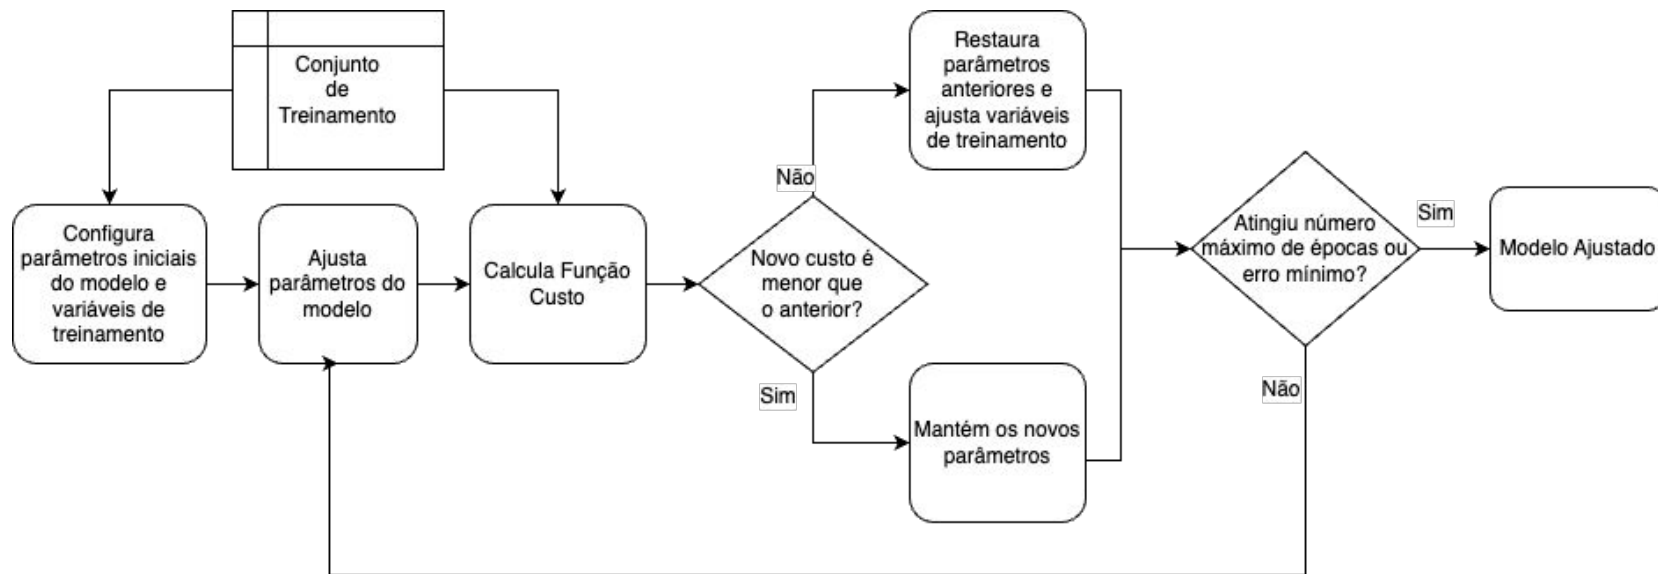
  for (j=0; j<n; j++)
    θj = newθj
}
```

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}$$

$$h(x) = g(z) = \frac{1}{1 + e^{-z}}$$

$$z = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

Treinamento do Modelo



Leitura recomendada: [O gradiente \(artigo\) | Khan Academy](#)

Lista 3

- Regressão Linear Simples, Múltipla e Logística
- Data de entrega: segunda, 22/05, até 23h59